


The background is a solid red color with two large, light-red, organic, blob-like shapes. One shape is in the upper left, and the other is in the lower left, partially overlapping the title text.

RAG para Calibração de Confiança em Autocompletadores de Código

Camila Barbosa Vieira
José Vinicius de Santana Souza
Matheus Lafayette Vasconcelos
Rafael dos Reis Labio

Motivação

- LLMs estão transformando o desenvolvimento de software.
- Mesmo assim, eles frequentemente geram código com bugs e vulnerabilidades.
- Desenvolvedores precisam saber quando confiar no código gerado.
- Confiança bem calibrada permite decisões mais informadas e revisões proporcionais ao risco.

Problemática

- Modelos como GPT-3.5 frequentemente apresentam excesso de confiança
- Exemplo: completions com 90% de confiança passam só 52% dos testes
- Isso pode levar desenvolvedores a aceitar código incorreto sem perceber

Calibração

- Um modelo está bem calibrado quando sua confiança prevista reflete a probabilidade real de acerto
- Exemplo: previsões com 80% de confiança devem estar corretas em ~80% dos casos
- Avaliamos isso usando métricas como:
 - Brier Score: Diferença quadrática entre a confiança prevista pelo modelo e o resultado real.
 - Skill Score: Quanto o modelo melhora em relação a um baseline.
 - ECE: Diferença média entre a confiança prevista e a frequência real de acertos.

Pergunta de Pesquisa

- RQ4: O few-shot prompting melhora a calibração reflexiva da confiança do modelo?
- Abordagem: Usamos reflexão — o modelo gera o código e depois responde:
 - "Esse código está correto? True/False"
- A confiança é extraída da probabilidade atribuída ao token "True"

Cenário Experimental

- Tarefa: Line-Level Code Completion
- Dataset: DYPYBENCH
 - 50 projetos reais em Python
- A correção do código gerado é verificada comparando a linha gerada e a linha original.
- Modelos usados:
 - deepseek-coder-1.3b

```
"original_line": "return (ddy * dx - ddx * dy) / ((dx ** 2 + dy ** 2)**(3 / 2))",  
"predicted_line": "return (dx*ddy - dy*ddx) / (dx**2 + dy**2)**1.5",  
"
```

Metodologia



- Utilizamos o modelo para avaliar sua própria saída, após gerar uma linha de código
- Prompt reflexivo:
 - “Dado o seguinte código gerado, ele está correto? Responda apenas com True ou False”
- Extraímos a probabilidade (pNB) associada à resposta "True" como medida de confiança
- A corretude real foi determinada analisando a correspondência
- Métricas de avaliação de calibração: Brier Score, Skill Score e ECE

Experimento

- Introduzimos few-shot ao prompt reflexivo contendo:
 - Função, linha gerada e ground-truth (True/False)
- Hipótese: exemplos similares ajudam o modelo a calibrar melhor sua confiança reflexiva
- Os exemplos foram selecionados:
 - Aleatoriamente: Sem critério de similaridade;
 - BM25: Base em similaridade lexical entre função e linha gerada;
 - RAG: Base em embeddings semânticos para recuperar os exemplos mais próximos no espaço vetorial




Comparação

- Resultados para **pavg**



Comparação

- Rescaling




Resultados

DYPYBENCH/deepseek-coder-1.3b


	Brier Score	Skill Score	ECE
Zero-Shot	0.26	-0.53	0.28
Few-Shot Aleatório	0.17	-0.05	0.10
BM25	0.03	0.83	0.07
RAG	0.02	0.88	0.09

Resultados


Zero-Shot




Few-Shot Random



Few-Shot BM25



RAG



Comparação

- Resultados

Confidence Measure	$\mathcal{B} \downarrow$	$SS \uparrow$	$ECE \downarrow$
0-Shot Reflect	0.25	-0.15	0.15
0-Shot Reflect (Rescaled)	0.22	0.00	
FS Random	0.29	-0.29	0.21
FS Random (Rescaled)	0.22	0.0	
FS BM25	0.20	0.08	0.10
FS BM25 (Rescaled)	0.19	0.15	0.02

TABLE V: Few-shot reflective prompting using GPT-3.5 for line completion. ‘FS Random’ refers to selecting random few-shot examples. ‘FS BM25’ retrieves more relevant known completions. ECE values when rescaled values SS are close to zero are omitted (to avoid confusion with “bucket collapse”, Section IV-B0a)

Confidence Measure	$\mathcal{B} \downarrow$	$SS \uparrow$	$ECE \downarrow$
0-Shot Reflect	0.26	-0.53	0.28
0-Shot Reflect (Rescaled)	0.17	-0.01	0.04
FS Random	0.17	-0.05	0.10
FS Random (Rescaled)	0.16	0.03	0.03
FS BM25	0.03	0.83	0.07
FS BM25 (Rescaled)	0.03	0.83	0.08
RAG	0.02	0.88	0.09
RAG (Rescaled)	0.02	0.86	0.10

Conclusão

- Modelo usado: DeepSeek-Coder-1.3B (vs GPT-3.5 no paper original)
 - Mesmo menor, teve boa performance com few-shot + RAG
- RAG apresentou boas métricas mas sofreu com bucket collapse
 - O desempenho pode ter sido prejudicado pela quantidade de dados
- FS-MB25 continuou tendo o melhor desempenho
- Isotonic rescaling ajuda caso a quantidade de dados seja alta

Trabalhos Futuros

- Incluir execução de testes automatizados
- Expandir o conjunto de modelos avaliados
- Avaliar outros benchmarks além do DYPYBENCH
- Investigar calibração sob diferentes tipos de erro
 - Ex: erros sintáticos vs semânticos vs lógicos
- Analisar impacto do conteúdo da docstring
- Executar a reflexão múltiplas vezes com temperatura > 0